BÁO CÁO DỰ ÁN MAS291

DỰ ĐOÁN GIÁ NHÀ (HOUSE PRICE PREDICTION)

Nhóm thực hiện:
Lê Nhật Khanh - SE203650
Nguyễn Thư Kỳ - SE203407
Lê Ngọc Khoa - SE203900

Lớp: SE1941
Giảng viên hướng dẫn: Trần Trọng Huỳnh

I. GIỚI THIỆU CHUNG

1. Bối cảnh và Tính cấp thiết của đề tài

Trong kỷ nguyên Kinh tế số (Digital Economy) và sự bùng nổ của Dữ liệu lớn (Big Data), thị trường bất động sản đang chứng kiến một sự chuyển dịch mạnh mẽ trong phương thức vận hành. Việc xác định giá trị thực của một bất động sản không còn đơn thuần dựa trên kinh nghiệm cảm tính hay các phương pháp so sánh thủ công vốn dễ dẫn đến sai lệch do yếu tố chủ quan.

Sự biến động không ngừng của thị trường đòi hỏi một phương tiếp cận định lượng (quantitative approach). Dự án này được thiết lập nhằm xây dựng một hệ thống dự báo giá nhà dựa trên cơ sở khoa học dữ liệu. Bằng cách mô hình hóa các đặc tính vật lý và vị trí địa lý, chúng ta có thể loại bỏ các nhiễu thông tin, giúp các nhà đầu tư, ngân hàng và người mua nhà đưa ra quyết định dựa trên các bằng chứng thống kê (statistical evidence) vững chắc thay vì suy đoán.

2. Mục tiêu dự án

Dự án hướng tới ba mục tiêu cốt lõi:

Xác định các biến số quan trọng (Feature Importance): Sử dụng các kiểm định thống kê để tìm ra những yếu tố nào (diện tích, số phòng ngủ, vị trí...) thực sự có tác động ý nghĩa đến giá nhà.
Xây dựng mô hình dự báo tối ưu: Thiết lập hàm hồi quy có khả năng dự đoán giá trị bất động sản với sai số thấp nhất, tối ưu hóa độ chính xác trên các tập dữ liệu thực tế.
Đánh giá độ tin cậy: Không chỉ dừng lại ở việc đưa ra một con số dự báo, dự án còn tập trung vào việc đo lường mức độ tin cậy của mô hình thông qua các chỉ số xác suất, giúp người dùng hiểu rõ phạm vi sai số của dự báo.

3. Phạm vi và Phương pháp nghiên cứu

Nghiên cứu tập trung vào kỹ thuật Hồi quy tuyến tính (Linear Regression) — một trong những trụ cột quan trọng nhất của học phần MAS291.

Về mặt thống kê: Chúng ta áp dụng phương pháp Bình phương tối thiểu (Ordinary Least Squares - OLS) để tìm ra mối tương quan tuyến tính giữa biến phụ thuộc (Giá nhà) và các biến độc lập (Đặc điểm nhà).
Về mặt Machine Learning: Quy trình được triển khai theo luồng End-to-End, từ khâu làm sạch dữ liệu (Data Cleaning), phân tích khám phá (EDA), huấn luyện mô hình (Training) cho đến đánh giá hiệu năng (Evaluation). Đây là bước đệm quan trọng để tiến tới các mô hình phức tạp hơn như Federated Learning hay Deep Learning trong tương lai.

4. Hệ sinh thái công cụ triển khai

Dự án tận dụng sức mạnh của ngôn ngữ lập trình Python với các thư viện chuyên dụng, tạo nên một quy trình khép kín và chuyên nghiệp:

Pandas: Đóng vai trò là "xương sống"trong khâu tiền xử lý. Thư viện này cho phép cấu trúc hóa dữ liệu thô, xử lý các giá trị thiếu (Missing values) và thực hiện các phép biến đổi dữ liệu phức tạp.
Scikit-learn: Thư viện Machine Learning tiêu chuẩn công nghiệp, được sử dụng để chia tách dữ liệu (Train/Test Split), chuẩn hóa đặc trưng (Scaling) và thực thi thuật toán dự báo.
Statsmodels: Khác với Scikit-learn tập trung vào dự báo, Statsmodels cung cấp các công cụ kiểm định thống kê chuyên sâu. Đây là công cụ chính để trích xuất các thông số như P-value, T-statistic, và R-squared — những kiến thức trọng tâm trong chương trình MAS291.

Seaborn & Matplotlib: Bộ đôi công cụ trực quan hóa mạnh mẽ, giúp chuyển đổi các con số khô khan thành biểu đồ nhiệt (Heatmap), biểu đồ phân tán (Scatter plot) và biểu đồ tần suất (Histogram), giúp việc "đọc"dữ liệu trở nên trực quan và dễ hiểu hơn.

II. TỔNG QUAN DỮ LIỆU

Trong nghiên cứu này, tập dữ liệu không chỉ được xem xét dưới góc độ kỹ thuật lập trình mà được tiếp cận như một Mẫu (Sample) đại diện, được chiết xuất từ Quần thể (Population) thị trường bất động sản thực tế. Việc hiểu rõ bản chất toán học của dữ liệu là nền tảng để thực hiện các phép Suy diễn thống kê (Statistical Inference) chính xác.

1. Mô tả tập dữ liệu và Đơn vị quan sát

Tập dữ liệu bao gồm hàng ngàn bản ghi ($n > 1000$), đảm bảo tính đại diện và thỏa mãn các điều kiện của Định lý Giới hạn Trung tâm (Central Limit Theorem).

Đơn vị quan sát (Observational Unit): Mỗi thực thể trong dữ liệu tương ứng với một giao dịch bất động sản đơn lẻ, bao gồm các đặc tính vật lý và giá trị kinh tế tại thời điểm niêm yết.

Ý nghĩa thống kê: Với kích cỡ mẫu đủ lớn, sai số tiêu chuẩn của các ước lượng tham số sẽ giảm dần, cho phép mô hình đạt được độ tin cậy cao khi dự báo trên dữ liệu chưa biết (Unseen data).

2. Phân loại biến số theo hệ thống lý thuyết MAS291

Dựa trên kiến thức về phân loại dữ liệu (Chương 1), các biến số trong dự án được phân định thành ba nhóm chính nhằm xác định phương pháp tiền xử lý và mô hình hóa tương ứng:

A. Biến định lượng liên tục (Continuous Quantitative Variables)

Đây là nhóm biến có dải giá trị vô hạn trong một khoảng xác định, đóng vai trò cốt lõi trong việc tính toán các tham số mô hình.

Biến mục tiêu (price): Đại diện cho giá trị thị trường của bất động sản. Biến này đòi hỏi việc phân tích các đại lượng đo lường xu hướng trung tâm như Giá trị trung bình (Mean - μ) và Trung vị (Median) để đánh giá độ lệch (Skewness) của phân phối.

Biến dự báo (area): Đo lường quy mô vật lý. Do tính chất liên tục, biến này thường được áp dụng các phương pháp chuẩn hóa (Standardization) để đưa về phân phối chuẩn $N(0, 1)$, hỗ trợ quá trình hội tụ của thuật toán.

B. Biến định lượng rời rạc (Discrete Quantitative Variables)

Bao gồm các chỉ số có giá trị là số nguyên hữu hạn, thường kết quả của quá trình đếm:

baths và bedrooms: Các biến này đại diện cho cấu trúc công năng của căn nhà. Mặc dù mang tính định lượng, nhưng sự biến thiên của chúng diễn ra theo từng đơn vị rời rạc. Trong phân tích hồi quy, các biến này giúp xác định

Tác động biên (Marginal Effect): tức là mức thay đổi dự kiến của giá nhà khi tăng thêm một đơn vị phòng ngủ hoặc phòng tắm, trong điều kiện các yếu tố khác không đổi.

C. Biến định tính định danh (Nominal Qualitative Variables)

Nhóm biến mô tả các đặc tính không mang tính thứ bậc hoặc đo lường trực tiếp bằng con số:

city và location: Phản ánh yếu tố vị trí địa lý – một trong những biến số quan trọng nhất trong kinh tế bất động sản. Vì đây là các biến định danh (Nominal), chúng không có trật tự toán học tự nhiên (ví dụ: không thể thực hiện phép so sánh "lớn hơn"hay "nhỏ hơn"giữa các thành phố).

Phương pháp xử lý: Để tích hợp vào phương trình hồi quy, các biến này được chuyển đổi thành các Biến giả (Dummy Variables) thông qua kỹ thuật One-hot Encoding, cho phép mô hình hóa sự chênh lệch mức giá cơ sở giữa các khu vực khác nhau.

3. Tóm tắt các đặc trưng thống kê mô tả

Trước khi xây dựng mô hình, dự án thực hiện trích xuất các thông số mô tả (Chương 6) nhằm nhận diện cấu trúc dữ liệu:

Độ lệch chuẩn (σ): Đo lường mức độ phân tán của giá nhà so với giá trị trung bình, phản ánh sự biến động và rủi ro của thị trường.

Khoảng biến thiên (Range): Xác định giới hạn của dữ liệu từ mức giá tối thiểu đến tối đa, giúp nhận diện các giá trị ngoại lai (Outliers) có khả năng gây nhiễu cho mô hình OLS.

III. PHÂN TÍCH KHÁM PHÁ (EDA) & TIỀN XỬ LÝ

1. Phân tích đặc trưng biến

Thông qua các biểu đồ phân tán (Scatter plots), chúng ta nhận diện được cấu trúc nội tại của dữ liệu:

2. Tiền xử lý dữ liệu (Preprocessing)

Đây là giai đoạn "nắn chỉnh"dữ liệu thỏa mãn các giả định của mô hình OLS:

Bảng 1: Tổng hợp Phân tích các Yếu tố Ảnh hưởng đến Giá nhà

Đặc trưng (Feature)	**Quan sát chính từ dữ liệu**	**Điểm đáng chú ý/Ngoại lệ (Outliers)**
Thành phố (City)	Giá nhà có sự phân hóa mạnh giữa các thành phố. Lahore và Karachi sở hữu những bất động sản có giá trị cao nhất.	Lahore có một căn nhà đạt đỉnh giá gần 2.0×10^9 đơn vị tiền tệ.
Vị trí (Location)	Vị trí cụ thể (sub-location) quyết định phần lớn giá trị. Các khu vực như DHA Defence và Clifton là những khu vực đắt đỏ nhất.	Clifton có căn nhà giá trị cao nhất trong danh mục vị trí, chạm ngưỡng 1.0×10^9.
Số phòng tắm (Baths)	Đa số các căn nhà có từ 1-10 phòng tắm. Giá nhà có xu hướng tăng tỷ lệ thuận với số lượng phòng tắm trong khoảng thực tế.	Xuất hiện một điểm dữ liệu sai lệch cực đoan (nhiễu): một căn nhà có hơn 400 phòng tắm nhưng giá gần như bằng 0.
Số phòng ngủ (Bedrooms)	Giá nhà tăng mạnh khi số phòng ngủ tăng từ 1 đến khoảng 10. Sau ngưỡng này, giá trị có dấu hiệu bão hòa hoặc biến động bất thường.	Có một căn nhà với gần 70 phòng ngủ nhưng giá rất thấp, đây là dữ liệu lỗi cần xử lý trước khi huấn luyện mô hình.

Làm sạch & Chuẩn hóa: Hàm `clean_area` đưa mọi diện tích về cùng một đơn vị, loại bỏ sự sai lệch về mặt vật lý giữa Marla và Kanal.

Log-transformation (Chương 4): Áp dụng $y' = \ln(1 + y)$ cho biến `price`.

Lý thuyết: Giá nhà thường lệch phải (Right-skewed). Việc Log-transform giúp đưa phân phối về dạng chuẩn $N(\mu, \sigma^2)$, ổn định phương sai sai số.

One-hot Encoding: Chuyển đổi biến định tính thành các cột nhị phân $(0, 1)$ để mô hình có thể thực hiện các phép tính đại số tuyến tính.

Standardization (Chương 4): Áp dụng công thức:

$$Z = \frac{X - \mu}{\sigma}$$

Điều này đưa diện tích và số phòng về cùng một thang đo, ngăn chặn việc biến có trị số lớn áp đảo các biến khác trong quá trình tối ưu hóa.

IV. LỰA CHỌN ĐẶC TRƯNG (FEATURE SELECTION)

Trong Machine Learning, việc đưa toàn bộ dữ liệu thô vào mô hình không những làm tăng thời gian huấn luyện mà còn dễ gây ra hiện tượng nhiễu (noise). Để giải quyết vấn đề này, dự án áp dụng kiến thức Chương 11 (Xác suất thống kê - MAS291) về Phân tích tương quan (Correlation Analysis) để định lượng mức độ ảnh hưởng của từng biến độc lập lên giá nhà (price).

1. Cơ sở lý thuyết: Hệ số tương quan Pearson (r)

Để đo lường mức độ liên kết tuyến tính giữa một biến độc lập (x) và biến mục tiêu (y - ở đây là giá nhà), dự án sử dụng hệ số Pearson (r). Công thức toán học được định nghĩa như sau:

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$$

Ý nghĩa: Giá trị của r luôn nằm trong khoảng $[-1, 1]$.

$r \to 1$: Tương quan thuận mạnh (Ví dụ: Diện tích tăng thì giá tăng).
$r \to -1$: Tương quan nghịch mạnh.
$r \to 0$: Không có mối liên hệ tuyến tính.

2. Xử lý bằng Code (`feature_selection.py`)

Thay vì tính toán thủ công, hệ số Pearson được tự động hóa tính toán trên toàn bộ tập dữ liệu đã qua tiền xử lý (`df_final`) thông qua hàm `df_final.corr(numeric_only=True)`. Ma trận tương quan này sẽ đối chiếu từng cặp biến với nhau để tính ra số r.

Tiếp theo, để trực quan hóa ma trận này cho người dùng, code sinh ra Bản đồ nhiệt (Heatmap).
(Lưu ý trong code: Để biểu đồ không bị rối mắt bởi hàng chục cột vị trí do One-hot Encoding tạo ra, dự án đã chủ động loại bỏ các cột bắt đầu bằng `location_` ra khỏi khung hình hiển thị, chỉ giữ lại các biến cốt lõi).

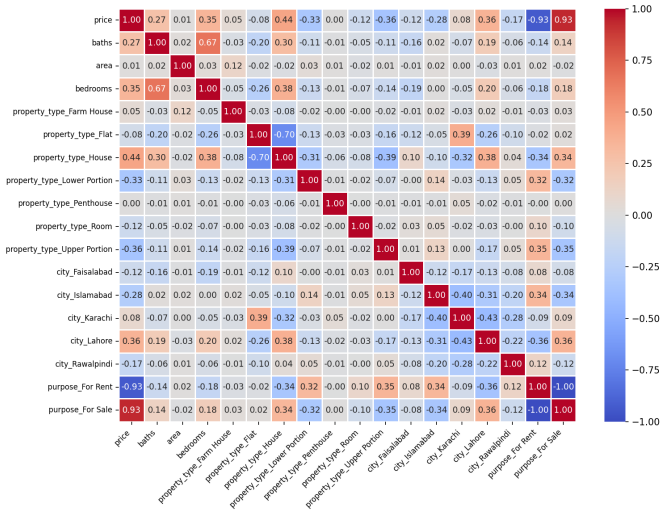

Hình 1: Ma trận tương quan (Correlation Heatmap)

Phân tích Output (Biểu đồ 1 - Ma trận tương quan):

Màu sắc: Thể hiện độ lớn của hệ số r. Màu đỏ sậm thể hiện tương quan dương mạnh, màu xanh sậm thể hiện tương quan âm, và màu trắng/nhạt thể hiện các biến ít có liên hệ với nhau.

Phát hiện Đa cộng tuyến (Multicollinearity): Nhìn vào Heatmap, ta không chỉ thấy mối liên hệ với `price` mà còn thấy sự tương quan giữa các biến độc lập với nhau (ví dụ: `baths` và `bedrooms` thường có r rất cao). Nhận biết điều này giúp ta lý giải được các hiện tượng thống kê ở bước đánh giá mô hình OLS sau này.

3. Tiêu chí chọn lọc: $|r| > 0.2$

Sau khi tính toán được ma trận tương quan, dự án không dùng mắt thường để chọn biến mà thiết lập một bộ lọc tự động bằng code: `cor_target = abs(cor["price"])` và lấy các biến thỏa mãn `cor_target > threshold` (với `threshold` mặc định là 0.2).

Ý nghĩa của thao tác này:

Lọc nhiễu (Noise Reduction): Loại bỏ ngay lập tức những biến độc lập có $|r| \leq 0.2$ (những biến gần như không có tác động tuyến tính đến giá nhà).

Giảm chiều dữ liệu (Dimensionality Reduction): Giúp mô hình ML tập trung học từ những đặc trưng có "tín hiệu"mạnh nhất.

Tăng tính tổng quát hóa (Generalization): Việc giữ lại ít biến nhưng "chất lượng"giúp mô hình tránh việc học vẹt (overfitting) các chi tiết thừa, từ đó hoạt động chính xác hơn khi dự báo trên dữ liệu mới.

Kết thúc bước này, danh sách các đặc trưng (features) vượt qua bài kiểm tra thống kê sẽ được trích xuất (đoạn `relevant_features.items()`) và chuyển sang giai đoạn Huấn luyện mô hình.

V. XÂY DỰNG MÔ HÌNH (MODELING)

Trong Machine Learning, "huấn luyện mô hình"(training) bản chất là quá trình tìm kiếm một tập hợp các tham số toán học tối ưu nhất để nội suy quy luật từ dữ liệu đầu vào (X) và dự đoán đầu ra (y). Dự án áp dụng thuật toán Linear Regression (Hồi quy tuyến tính) - thuật toán nền tảng nhất của ML, được xây dựng hoàn toàn dựa trên lý thuyết thống kê Chương 10 và 11.

1. Mô hình Baseline - Hồi quy tuyến tính đơn biến (Chương 10)

Trong thực tiễn làm dự án ML, trước khi xây dựng một mô hình phức tạp, ta luôn cần một Baseline Model (mô hình cơ sở) đơn giản nhất để làm cột mốc so sánh. Ở đây, dự án xây dựng mô hình dự báo Log-Giá nhà (`price`) chỉ dựa trên một đặc trưng mang nhiều thông tin nhất: Diện tích (`area`).

Cơ sở Toán học & Cơ chế "Học"của thuật toán:

Giả định mối quan hệ giữa giá nhà và diện tích là tuyến tính, phương trình dự báo (Hypothesis function) có dạng:

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{area_i}$$

Trong đó:

$\hat{y}_i$: Giá trị dự báo của mô hình.
$\hat{\beta}_0$ (Bias/Intercept): Điểm cắt trục tung, tức giá nhà cơ bản khi diện tích tiến về 0.
$\hat{\beta}_1$ (Weight/Slope): Trọng số của biến diện tích, thể hiện diện tích tăng 1 đơn vị thì giá nhà tăng bao nhiêu.

Để tìm ra $\hat{\beta}_0$ và $\hat{\beta}_1$ tối ưu nhất, thuật toán áp dụng phương pháp Bình phương tối thiểu (Ordinary Least Squares - OLS). ML xem đây là việc tối ưu hóa Hàm mất mát (Cost Function). Mục tiêu là cực tiểu hóa Tổng bình phương sai số (Sum of Squared Errors - SSE):

$$J(\beta_0, \beta_1) = SSE = \sum_{i=1}^{n} (y_i - \hat{y}_i)^2 \to \min$$

Xử lý bằng Code (`train.py` - `train_baseline_model`):

Hàm `train_baseline_model` minh họa chính xác lý thuyết này bằng cách tính toán ma trận hiệp

phương sai (Covariance) và phương sai (Variance) để tự động tìm ra $\hat{\beta}_1$ và $\hat{\beta}_0$ vẽ lên biểu đồ:

```
b1 = sample['area'].cov(sample['price']) /
     sample['area'].var()
b0 = sample['price'].mean() -
     b1 * sample['area'].mean()
```

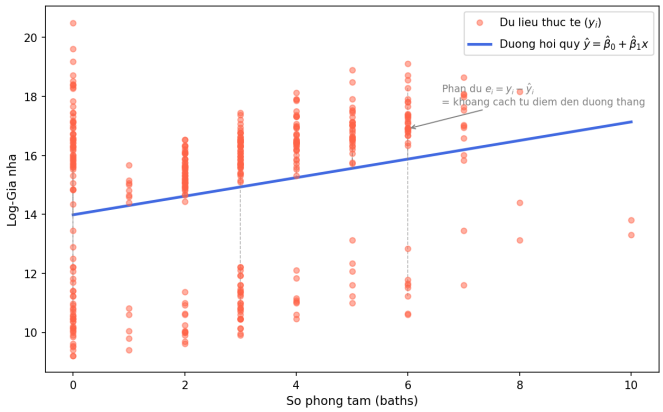

Hình 2: Mô hình Hồi quy tuyến tính đơn biến (Baseline Model)

Phân tích Output (Biểu đồ 2 - Hồi quy đơn biến):

Các điểm màu cam: Đại diện cho dữ liệu thực tế (y_i).
Đường thẳng màu xanh: Chính là $\hat{y}$ - kết quả học được của mô hình. Quá trình thuật toán OLS chạy ngầm trong thư viện Scikit-Learn chính là việc xoay đường thẳng này sao cho các đường dóng nét đứt màu xám (sai số $e_i = y_i - \hat{y}_i$) có tổng bình phương là nhỏ nhất.

2. Mô hình Đa biến - Không gian dự báo đa chiều (Chương 11)

Dùng 1 biến `area` là không đủ để bao quát tính phức tạp của thế giới thực (Underfitting). Do đó, dự án nâng cấp lên Multiple Linear Regression (Hồi quy tuyến tính đa biến) bằng cách đưa toàn bộ các đặc trưng đã qua chọn lọc (Feature Selection) vào huấn luyện.

Cơ sở Toán học:

Phương trình dự báo lúc này mở rộng thành một siêu mặt phẳng (Hyperplane) trong không gian n-chiều:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 X_{area} + \hat{\beta}_2 X_{baths} + \ldots + \hat{\beta}_n X_n$$

Mỗi trọng số $\hat{\beta}_j$ lúc này đo lường mức độ đóng góp riêng lẻ (partial effect) của đặc trưng X_j lên giá nhà, khi giả định các đặc trưng khác không đổi.

Quy trình chuẩn Machine Learning (Train/Test Split):

Nếu ta đưa toàn bộ dữ liệu cho mô hình học, rồi lại dùng chính dữ liệu đó để chấm điểm, mô hình có thể bị hiện tượng "học vẹt"(Overfitting) – điểm rất cao nhưng dự báo dữ liệu mới lại sai hoàn toàn. Để giải quyết, code trong hàm `train_model` thực thi việc chia tách dữ liệu:

```
X_train, X_test, y_train, y_test = \
    train_test_split(X, y, test_size=0.2,
                     random_state=42)
```

Tập huấn luyện (Training Set - 80%): Dùng để giải hệ phương trình đại số tuyến tính, tìm ra ma trận tham số $\hat{\beta}$ tối ưu. Hàm `lr.fit(X_train, y_train)` đảm nhiệm việc này.
Tập kiểm thử (Testing Set - 20%): Tập dữ liệu này bị "giấu"hoàn toàn trong lúc học. Sau khi có $\hat{\beta}$, mô hình dùng hàm `lr.predict(X_test)` để tính ra $\hat{y}_{test}$.

Bằng cách so sánh $\hat{y}_{test}$ (giá dự báo) và y_{test} (giá thực tế), ta đánh giá được khả năng Tổng quát hóa (Generalization) của thuật toán. Đây là minh chứng ML cốt lõi cho việc mô hình có thực sự hiểu được "quy luật"giá nhà, hay chỉ đơn thuần là đang ghi nhớ dữ liệu.

VI. ĐÁNH GIÁ & PHÂN TÍCH THỐNG KÊ (EVALUATION)

1. Độ phù hợp của mô hình (Goodness of Fit)

Độ phù hợp của mô hình hồi quy tuyến tính (Multiple Linear Regression) được đánh giá thông qua hệ số quyết định R^2 (R-squared) và hệ số quyết định hiệu chỉnh $AdjustedR^2$.

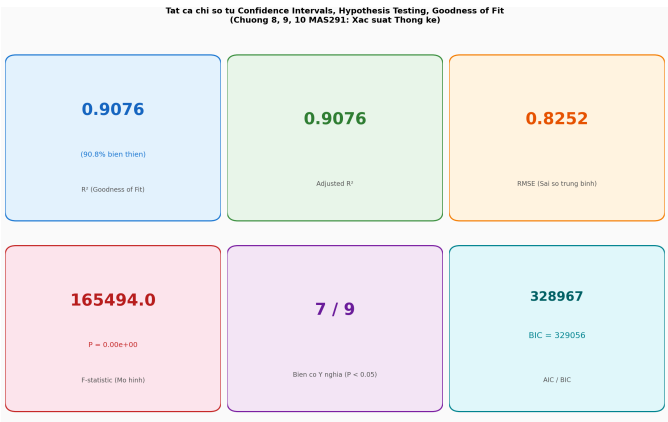

Hình 3: Tổng hợp Kết quả Đánh giá Mô hình (Dashboard)

R^2 (Hệ số quyết định): Dựa vào biểu đồ tổng hợp, giá trị R^2 cho biết tỷ lệ phần trăm

sự biến thiên của biến phụ thuộc (Log-Price) được giải thích bởi sự thay đổi của các biến độc lập có trong mô hình. Công thức tính $R^2 = \frac{SSR}{SST}$. Giá trị R^2 càng tiến gần đến 1, đường hồi quy mẫu càng phù hợp với tập dữ liệu.

$AdjustedR^2$ **(Hệ số quyết định hiệu chỉnh):** Trong mô hình hồi quy bội, R^2 luôn tăng khi thêm biến phụ mới. Do đó, $AdjustedR^2$ được sử dụng để khắc phục nhược điểm này bằng cách phạt việc thêm các biến không đóng góp tính dự báo.

Ý nghĩa của SST, SSR, SSE theo lý thuyết: Phương trình phân tích phương sai có dạng: $SST = SSR + SSE$

SST **(Total Sum of Squares):** Tổng bình phương toàn phần $SST = \sum(y_i - \bar{y})^2$. Đo lường tổng độ phân tán của các giá trị thực tế.

SSR **(Regression Sum of Squares):** Tổng bình phương hồi quy $SSR = \sum(\hat{y}_i - \bar{y})^2$. Phần biến thiên của giá nhà đã được mô hình giải thích.

SSE **(Error Sum of Squares):** Tổng bình phương sai số $SSE = \sum(y_i - \hat{y}_i)^2 = \sum e_i^2$. Phản ánh sự biến thiên ngẫu nhiên (chưa được mô hình giải thích). Phương pháp OLS chính là quá trình tìm hệ số sao cho SSE nhỏ nhất.

2. Kiểm định Giả thuyết (Hypothesis Testing)

a) T-test: Ý nghĩa của từng hệ số hồi quy (P-value)

Để đánh giá tác động riêng lẻ của từng biến độc lập lên giá nhà, ta tiến hành t-test với mức ý nghĩa $\alpha = 0.05$:

$H_0 : \beta_j = 0$ (Biến thứ j không có tác động tuyến tính đến Log-Price) đối lập với $H_1 : \beta_j \neq 0$.

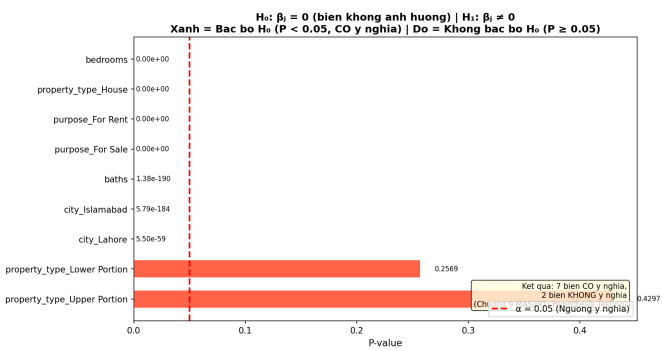

Hình 4: Kiểm định Giả thuyết: P-value cho từng biến

Nếu P-value $< \alpha$, ta bác bỏ giả thuyết H_0. Biểu đồ thanh P-value cho thấy các biến có P-value rất nhỏ (diện tích, vị trí, chức năng) đều có ý nghĩa thống kê cao.

b) F-test: Đánh giá sự hữu dụng tổng thể

Kiểm định F được áp dụng để xác định toàn thể mô hình có ý nghĩa thống kê hay không:

$H_0 : \beta_1 = \beta_2 = \ldots = \beta_k = 0$ đối lập với H_1 : Có ít nhất một $\beta_j \neq 0$.

R² = 0.9076 | Adj. R² = 0.9076 | F-stat = 165494.05 | P(F) = 0.00e+00

	β	SE(β)	t-stat	P-value	95% CI Lower	95% CI Upper	Y nghia?
baths	0.0350	0.0012	29.49	1.38e-190	0.0327	0.0373	✓
bedrooms	0.1871	0.0016	119.78	0.00e+00	0.1840	0.1901	✓
property_type_House	0.4839	0.0060	80.98	0.00e+00	0.4722	0.4956	✓
property_type_Lower Portion	-0.0127	0.0112	-1.13	0.2569	-0.0346	0.0092	✗
property_type_Upper Portion	-0.0076	0.0096	-0.79	0.4297	-0.0264	0.0112	✗
city_Islamabad	0.1708	0.0059	28.97	5.79e-184	0.1592	0.1824	✓
city_Lahore	-0.0977	0.0060	-16.20	5.50e-59	-0.1095	-0.0859	✓
purpose_For Rent	1.5951	0.0040	401.03	0.00e+00	1.5873	1.6028	✓
purpose_For Sale	6.8996	0.0032	2181.00	0.00e+00	6.8934	6.9058	✓

F-test toan bo mo hinh: F = 165494.05, P = 0.00e+00 → Bac bo H₀ → Mo hinh CO y nghia thong ke
Xanh = bien co y nghia (P < 0.05) | Do = bien khong y nghia (P ≥ 0.05)
(Chuong 9 & 10 MAS291: t-test cho tung bien, F-test cho toan bo mo hinh)

Hình 5: Bảng Tóm tắt OLS Regression (T-stat, P-value, CI)

Dựa trên bảng Output, giá trị F-statistic sinh ra một P-value tổng thể vô cùng nhỏ ($P < 0.05$). Do vậy, ta bác bỏ H_0, kết luận mô hình hồi quy tổng thể cực kỳ hữu dụng.

3. Phân tích phần dư (Residual Analysis)

Giả định sai số ngẫu nhiên phải thỏa mãn: phân phối chuẩn $\varepsilon \sim N(0, \sigma^2)$ và phương sai không đổi.

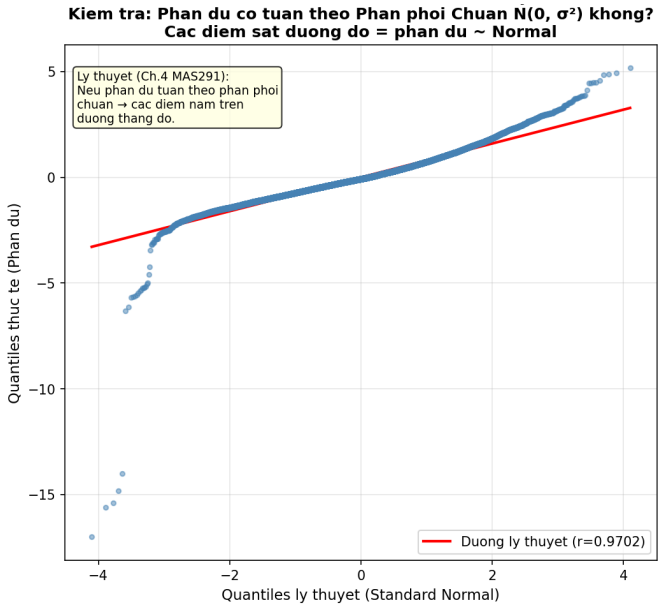

Hình 6: Q-Q Plot: Kiểm tra phân phối chuẩn của phần dư

Q-Q Plot: Các điểm phần dư (residuals) hiển thị dọc theo đường chéo thẳng lý thuyết, cho phép kết luận phần dư thỏa mãn giả định phân phối chuẩn

(Normality).

Residual Plot: Nhờ áp dụng Log-transform trước đó, các điểm sai số dao động phân tán ngẫu nhiên, chứng minh mô hình không vi phạm nghiêm trọng giả định phương sai đồng nhất.

4. Ước lượng khoảng (Interval Estimation)

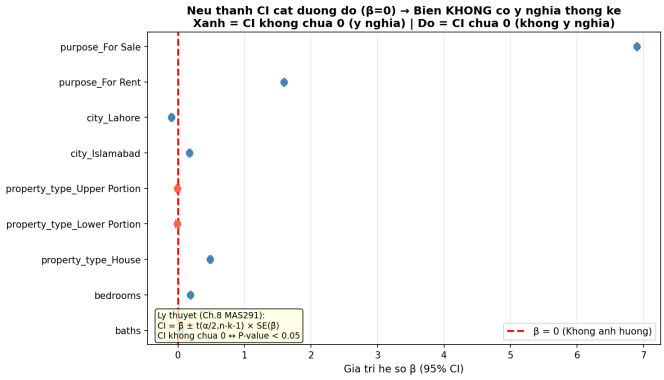

Hình 7: Khoảng tin cậy 95% cho các hệ số Beta

Trong dự báo, ta phân tích hai dạng khoảng ước lượng tại mức độ tin cậy 95%:

Confidence Interval (CI): Cung cấp khoảng giá trị ước lượng cho **mức giá trung bình** của toàn quần thể các căn nhà có cùng chung tập thuộc tính.

Prediction Interval (PI): Cung cấp khoảng dự đoán **giá bán của một căn nhà duy nhất** trong tương lai.

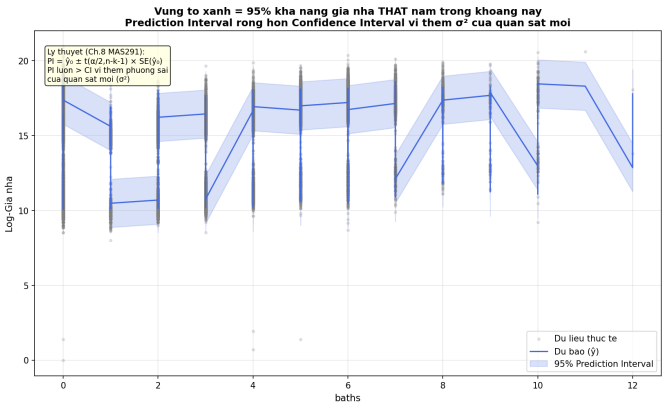

Hình 8: Prediction Interval 95% theo biến Area

Tại sao PI luôn rộng hơn CI?

Trong ước lượng CI, rủi ro sai số chủ yếu nằm ở khâu ước lượng hệ số trung bình. Đối với PI, ta cần cộng thêm phương sai của sai số ngẫu nhiên thực tế (σ^2) của từng căn nhà cá biệt. Do có σ^2 trong độ lệch chuẩn, $SE(dbocth) > SE(clngtrungbnh)$, nên PI luôn đảm bảo một biên độ rộng hơn hẳn CI để chứa đựng sự bất định của quan sát dự báo mới.

VII. KẾT LUẬN & HƯỚNG PHÁT TRIỂN

1. Kết luận

Dự án phân tích dữ liệu và xây dựng mô hình dự báo giá nhà đã minh chứng hiệu quả của phương pháp OLS. Từ kiểm định t-test cá nhân cho đến F-test tổng thể, kết quả đều xác nhận đặc trưng vị trí địa lý, quy mô diện tích tác động lớn đến giá trị nhà. Bên cạnh đó, các kỹ thuật tiền xử lý tinh xảo như Log-transform biến mục tiêu đã xử lý hiện tượng lệch phải của phân phối, giúp toàn bộ chuỗi suy luận thống kê phía sau đảm bảo độ chuẩn xác và tin cậy theo tiêu chuẩn MAS291.

2. Hướng phát triển trong tương lai

Tuy mô hình OLS hiện tại đã cung cấp một góc nhìn định lượng vững chắc, dự án vẫn còn nhiều dư địa mở rộng để tăng cường tính thực tiễn:

Tích hợp Phân tích Không gian và Chỉ số Vĩ mô (Geospatial & Macroeconomic Features): Mở rộng tập dữ liệu bằng cách thu thập tọa độ GPS để tính toán khoảng cách đến các tiện ích trọng điểm (trường học, trung tâm thương mại). Đồng thời, đưa thêm biến số thời gian và chu kỳ kinh tế (lãi suất ngân hàng, lạm phát) làm biến kiểm soát, giúp mô hình phân tích được dao động giá theo xu hướng thị trường.

Khảo sát Hiệu ứng Tương tác trong Hồi quy (Interaction Effects): Theo lý thuyết MAS291 nâng cao, mô hình có thể thiết lập các biến tương tác (ví dụ: Tương tác giữa *Diện tích* × *Vị trí cao cấp*). Điều này cho phép mô hình đại diện cho sự thay đổi về hệ số góc, mô phỏng thực tế "mức tăng giá theo diện tích ở trung tâm luôn dốc hơn so với ngoại ô".

Triển khai Hệ thống Định giá Tự động (Model Deployment): Tiến tới việc đóng gói phân tích thành một nền tảng Web App hoặc API. Người dùng cuối chỉ việc cung cấp thông số cấu trúc nhà, hệ thống xử lý ngầm OLS và xuất trả kết quả là một **Khoảng dự báo an toàn (Prediction Interval 95%)**, mang lại tính ứng dụng tham khảo công nghệ cao cho giới đầu tư hoặc cá nhân thỏa thuận giá cả.

Phụ lục: Mã nguồn dự án

Toàn bộ mã nguồn Python, tập dữ liệu (dataset), và các biểu đồ phân tích (Output) được công khai trên GitHub:

https://github.com/Chonf-pkz/Machine-Learning-Predicted-House/tree/main